

ZLC FPGA Pulse Streamer 手册

Artix-7 35T 边沿流送器 / 1-tick 预取 / 无限流式扫描 / JTAG-to-AXI

RTL、1-tick 预取、双 bank 流式、仿射扫描引擎、模拟总线 DAC、编译上传流
程、资源预算

2026-06-09

Contents

1	写给新读者	1
1.1	这块硬件是什么	1
1.2	两句话能力总结	1
1.3	文件	2
2	架构总览	3
2.1	从主机到引脚的一条链	3
2.2	CTRL 寄存器邮箱	3
2.3	一行边沿的含义	4
2.4	时钟与对齐	4
3	1-tick 预取流水线	5
3.1	为什么需要预取	5
3.2	解法: 深度 FIFO_DEPTH 的连续预取 + 影子	5
3.3	背靠背 1-tick 边沿: 前端脉冲实绘	5
4	无缝边界: 四个 gapless 重装点	7
4.1	边界为什么不留缝	7
4.2	扫描点 $k \rightarrow k+1$ 跨界无缝: 前端脉冲实绘	7
5	无限流式扫描: 2-bank ping-pong	9
5.1	窗口 + 流式回填	9
5.2	bank_chunk 握手与晚到 STALL	9
5.3	repeat_forever 流式重扫	10
6	N-slot 仿射扫描引擎	11
6.1	核心公式	11
6.2	为什么这是对的取舍	11
7	模拟总线 DAC 引擎	12
7.1	段表编码	12
7.2	模拟 DAC ramp 与扫描端点: 前端脉冲实绘	12

8	三个子系统的深入讨论	14
8.1	AXI4 突发上传	14
8.2	逐通道字面输出延时线 (delay line)	15
8.3	DAC 总线延时与 TTL 完全同源	16
8.4	逐通道 clk 输出 (把某通道直接接到时钟)	16
8.5	两件没有下放进 sequencer 的事	17
9	容量与资源预算	18
9.1	35T 上解出的容量	18
10	编译与上传流程	19
10.1	build / program / run	19
10.2	一次上传里发生了什么	19

1

写给新读者

1.1 这块硬件是什么

pulse-streamer 是一个**固定 bitstream + 运行时表**的脉冲序列器。烧一次 bitstream 就得到时钟状态机、板上输出引脚、`jtag_axi + axi_bram_ctrl` 数据通路和片上 BRAM；它**不把**某个具体实验脉冲写死进 Verilog。之后每次 `On Pulse`，主机都把当前的 `PulseTableState/PulseSequence` 编译成一张紧凑的程序映像，经 **JTAG-to-AXI** 写进 FPGA 的 BRAM，再用一个 CTRL 寄存器邮箱 (COMMAND/STATUS) 控制引擎运行。

这是**唯一**一套设计：没有变体、没有向后兼容、没有探针控制面、没有逐通道游程引擎、没有加载器 FSM。整条路径就是“主机打包 BRAM 映像 → AXI 写入 → CTRL 邮箱命令 → 边沿表引擎播放”。

目标器件

本设计面向 **Xilinx Artix-7 35T (xc7a35tfgg484-2)**，FGG484 封装。这是一颗 LUT/BRAM 资源有限的小器件，所以所有容量参数都按它来权衡。

近似资源类别：

xc7a35tfgg484-2

logic cells:	33,280	CLB LUTs:	20,800	CLB FFs:	41,600
BRAM:	1,800 Kb (50 x 36 Kb RAMB36)	DSP:	90		

1.2 两句话能力总结

- **最小脉冲宽度与分辨率 = 1 个 tick (20 ns)**。背靠背的 1-tick 边沿能逐周期、一拍一个地打出来——靠的是一条连续预取流水线把 BRAM 读延迟藏掉（见第三章）。
- **扫描点数无上限**。常驻一个 2-bank ping-pong 窗口 (4096 点)，主机在游标后面把空出来的 bank 流式回填下一段（见第五章）。配合 N-slot 仿射扫描，**duration 与 DAC 值**（仅这两类可扫）可以在**一次连续运行里任意组合地无缝扫描**；channel 延时**不是**扫描量，它是一条加在输出上的逐通道**字面延时线**（每条 channel 一个固定值，正/负/零，范围 $\pm 15 \mu s$ ，由有界深度 `DELAY_DEPTH` 的环形缓冲实现，见第六章）。

1.3 文件

fpga/pulse_streamer/zlc_edge_streamer.v 引擎。全局边沿表 (三块并行 BRAM: tick 32b / coeff 64b / mask 62b, 强制 `READ_LATENCY_B=2`)、深度 `FIFO_DEPTH(=RD_LAT+1=3)` 的连续边沿预取、2-bank ping-pong 扫描窗口、仿射有效 tick MAC、模拟总线 DAC 引擎。

fpga/pulse_streamer/zlc_pulse_streamer_top.v 顶层。`jtag_axi` → `axi_bram_ctrl` → 区段译码的 BRAM (三块并行边沿 + 扫描窗口 + 总线映像) + CTRL 寄存器邮箱, 驱动引擎与板上 62 路输出 + 4x10b DAC 总线。

fpga/pulse_streamer/host/image.py 主机 ↔ FPGA AXI 写契约 + 容量求解器的单一真相源。`pack_program/unpack_program` 打包/解码 BRAM 映像, `solve_capacity` 从器件 RAMB36/LUT 预算推导几何。RTL localparam 与 create-project Tcl 都从它派生。

fpga/pulse_streamer/host/engine_model.py 逐周期行为模型 (仓库没有 Verilog 仿真器, 这是硬件前的正确性证明)。

Zou_lab_control/neutral_atom/devices/axi_session.py 主机会话 `VivadoAxiStreamerSession`: 常驻 Vivado `hw_axi`, 打包上传 + 驱动 CTRL 邮箱 + 流式回填。

2

架构总览

2.1 从主机到引脚的一条链

真实路径是双电脑结构。控制电脑通过 RPyC 把命令发到 FPGA 电脑上的 server; server 持有一个常驻 Vivado `hw_axi` 会话, 用 JTAG-to-AXI 把程序映像写进 FPGA 的 BRAM, 再写 CTRL 寄存器命令引擎运行。




Figure 2.1: 数据通路: 主机经 JTAG-to-AXI 写区段译码的 BRAM 与 CTRL 邮箱; 引擎从 BRAM 播放, 并把 STATUS/CURSOR 回写邮箱供主机轮询/流式回填。

2.2 CTRL 寄存器邮箱

主机不碰任何探针; 它只读写一小块 CTRL 寄存器文件 (来自 `host.image.CtrlWords`):

CTRL mailbox			
COMMAND	主机->top	上升沿	LOAD(1) / FIRE(2) / RESET(4) / SAFE(8)
STATUS	top->主机		LOADED(1)/RUNNING(2)/DONE(4)/ERROR(8)/UNDERFLOW(16)
PROG_COUNT		边沿行数	
SCAN_COUNT		扫描点总数 N	(可超过常驻窗口)

```
SCAN_ENABLE / REPEAT_FOREVER
LOOP_START / LOOP_COUNT / LOOP_END_TICK / LOOP_END_LO / LOOP_END_HI
BUS_COUNTS / BANK_SIZE / SLOT_COUNT
CURSOR      top-> 主机    已消费的扫描点数（驱动流式回填）
BANK_READY  主机->top    bit b = bank b 已装好
BANK0_CHUNK / BANK1_CHUNK 主机->top  各 bank 当前装的是哪一段 chunk
```

生命周期: `prepare` (SAFE、上传映像、arm bank、LOAD) / `fire` (FIRE) / `wait_done` (轮询 STATUS、跟随 CURSOR 流式回填) / `safe_state` (SAFE)。COMMAND 字在每个命令前先清 0，制造干净的上升沿。

2.3 一行边沿的含义

引擎里保存一张全局边沿表，每行三个字段，分别存在三块**并行的** BRAM 里：

每行边沿

```
tick[i]   : 该边沿的基准 FPGA tick (32 bit)           -- TICK BRAM
coeff[i]  : NUM_SLOTS 个定点扫描系数 (NUM_SLOTS*16 bit) -- COEFF BRAM
mask[i]   : 该 tick 上完整的输出状态 (62 bit)         -- MASK BRAM
```

bit 0 对应 `channels[0]`。一行的含义是：**在这个有效 tick，把所有输出切换成这个 mask**——不是逐 channel 命令。三块 BRAM 并行读，所以一次访问拿到一整行边沿，无需位宽填充；`max_edges` 因此可以做大（35T 上 4096 行）。

2.4 时钟与对齐

真实硬件默认 50 MHz，一个 tick 是 20 ns。主机在上传前校验所有 period 持续时间、channel 延时、扫描点都对齐到这个 tick 网格 (`1e9 / clock_hz`)。32 位 tick 计数器在 50 MHz 下覆盖约 85.9 秒。同步后的 FIRE 路径会引入一个固定的小启动延迟，但那是常数偏移，不是比例因子；脉冲宽度和延时由 tick 计数决定。

3

1-tick 预取流水线

3.1 为什么需要预取

边沿表放在 block RAM 里, 而 block RAM 是**同步读**: 发出读地址后, 数据要 RD_LAT 个周期后才到。build tcl 用 `zlc_force_latency2` 把边沿 BRAM 强制成 $READ_LATENCY_B=2$, 所以 $RD_LAT=2$ 是确定的。如果天真地“到点了才去读下一行”, 每条边沿之间就至少要空 2 个周期——背靠背的 1-tick 边沿根本打不出来。

3.2 解法: 深度 FIFO_DEPTH 的连续预取 + 影子

引擎维护一个深度 $FIFO_DEPTH(=RD_LAT+1=3)$ 的“arm” FIFO, 里面装着**接下来要打的几条边沿**。它**每个周期发一次 BRAM 读**, 把读回的边沿压进 FIFO 尾; 当 `time_count` 追上 FIFO 头那条边沿的有效 tick 时, 就在**同一周期**把它的 mask 打到输出、并把它弹出。因为 FIFO 深度比读延迟多 1, FIFO 永远不空, 背靠背的 1-tick 边沿就能一拍一个地连续命中。

SEED 不变式 (行为模型逼出来的关键)

在每个边界, 从“第一条还没输出的边沿”开始**播种 FIFO_DEPTH 条影子**, 并且边界当拍**不发新读** (占用 == 影子数 $\leq$ 深度)。3 条影子刚好够给紧跟着的 1-tick 后继留出时间; 2 条影子会少一拍而丢边沿。这条不变式是逐 tick 镜像仿真“逼”出来的。

3.3 背靠背 1-tick 边沿: 前端脉冲实绘

边沿表放在 block RAM(同步读, $RD_LAT=2$), 引擎用一条深度 $FIFO_DEPTH=RD_LAT+1=3$ 的连续预取流水线把读延迟藏掉: 它**每周发一次 BRAM 读** (周期 T 发出的读, 数据在 $T+RD_LAT$ 落地), 读回的边沿压进 arm FIFO 尾; 当 `time_count` 追上 FIFO 头那条边沿的有效 tick 时, 在**同一周期**把它的 mask 打到输出并弹出。因为 FIFO 深度比读延迟多 1, 弹出与补充始终咬合、FIFO 不空。下图是**前端脉冲绘图器实绘**的引擎输出: 三路通道在相邻 20 ns tick 上背靠背切换, 每个 1-tick 边沿逐拍打出、中间无空拍——这正是 20 ns 的最小脉宽与分辨率。

- 周期 $-2, -1$ 是**arm 阶段** (reset/LOAD 期间): 连发读把前几条边沿的影子预取进 FIFO, 使 `time_count` 从 0 开始时 FIFO 已经有货。




Figure 3.1: 前端脉冲实绘: 三路通道在相邻 20 ns tick 上背靠背切换——引擎的最小脉宽与分辨率就是 1 个 tick; 预取流水线让这些 1-tick 边沿逐拍打出, 中间无空拍。

- tick 0: FIFO 头是 A 且 `time_count=tick[A]=0`, 当拍输出 A 并弹出; 同一拍 C 的数据正好落地补进 FIFO。
- 由于 FIFO 深度 3 > 读延迟 2, 弹出与补充永远咬合, tick 1/2/3 连续命中 B/C/D, 无空拍。

这条等价是被证明的

`host.engine_model.rtl_mirror_play` 在读延迟 1/2/3 下逐 tick 等于组合参考播放器 `reference_play`, 并跑了 200 个 fuzz 程序 (含背靠背 1-tick、扫描 1-tick、loop 1-tick)。仓库无 Verilog 仿真器, 这个逐周期镜像就是硬件前最强证据。

4

无缝边界：四个 gapless 重装点

4.1 边界为什么不留缝

引擎只有一个全局边沿指针，所以一次 repeat / loop-rewind / scan-advance / start 只是单周期的指针 + 影子重装。四个 gapless 重装点 (start / loop-rewind / scan-advance / repeat) 在边界用上一节的 SEED 不变式重新播种 FIFO_DEPTH 条影子，于是点 k 的最后一条边沿与点 $k+1$ 的第一条边沿在时间上紧挨着，中间没有缝。

4.2 扫描点 $k \rightarrow k+1$ 跨界无缝：前端脉冲实绘

仿射扫描把 duration/DAC 值绑到 slot $s_0 \dots s_N$ (channel 延时不是扫描量)；每个扫描点用新的 slot 向量，边沿的有效 tick = $\text{base} + (\text{sum coeff} * \text{slot}) \gg \text{FRAC}$ 随之平移。下图是前端实绘的同一脉冲在两个扫描点的输出——被扫的中间周期把后面的边沿在硬件里 lockstep 平移。引擎在播放点 k 末尾的同一拍，就已按 $k+1$ 的新 slot 向量把首批影子重新播种好，所以点 k 的末边沿与点 $k+1$ 的首边沿在时间上紧挨着、无 gap。




Figure 4.1: 前端脉冲实绘：同一脉冲在两个 scan 点的渲染。被扫的中间周期把后面的边沿在硬件里 lockstep 平移；扫描点之间的切换是无缝的（边界影子重装）。

- 边界处引擎不发新读，只用已经播种好的影子。新 slot 向量在边界当拍生效，所以下一点首条边沿的

有效 tick 已按 $k+1$ 的扫描值算好。

- `loop-rewind(repeat bracket)` 走同一套机制: 指针跳回 `loop_start_addr`, 影子按 loop 起点重新播种, 循环接缝同样无缝。下图是前端实绘的硬件重复 loop 循环体 (不展开), 重复之间无缝回绕。




Figure 4.2: 前端脉冲实绘: 硬件重复 loop 的循环体 (不展开)。 `repeat\_forever` 在硬件里无缝回绕, 重复之间不留缝。

`host.engine_model` 用 `streaming_scan_play` 与 1-tick 边界 fuzz 证明了这一点: 跨扫描点 / 跨 loop 的边沿与不分段的参考播放逐 tick 相同。

5

无限流式扫描：2-bank ping-pong

5.1 窗口 + 流式回填

扫描窗口在硬件里是一个 **2-bank ping-pong** ($BANK_SIZE=2048$ ，是 2 的幂；两 bank 共 4096 个常驻扫描点)，放在一块 BRAM 里。引擎依次播放点 $0..N-1$ ，用 $(idx/BANK_SIZE) \bmod 2$ 选 bank，并把已消费点数写进 **CURSOR**。主机读 **CURSOR**，把游标已经走过的那个 bank 回填**下一段 chunk**，并更新 **BANK_READY/BANK*_CHUNK**。这样扫描点文件虽然有限，但**大小无上限**。



Figure 5.1: 2-bank ping-pong: 引擎播放当前 bank、推进 CURSOR; 主机在游标背后把空出来的 bank 回填下一段 chunk。

5.2 bank_chunk 握手与晚到 STALL

引擎只在 **BANK_READY** 为真且该 bank 装的是**正确 chunk** ($BANK_CHUNK$ 与引擎期望的段号一致) 时才推进。如果回填来晚了，引擎**停住** (hold 在当前点，置 **STATUS_UNDERFLOW**)，**绝不**播放错误或过期的点；主机回填到位后它再继续。这把“晚到”变成一次安全的 hold，而不是数据损坏。

streaming refill timeline + late-refill STALL

```
CURSOR (pts done):  0 ..... 2047 | 2048 ..... 4095 | 4096 .....
engine plays bank:  bank0          | bank1          | bank0(chunk2)
BANK_READY         :  b0,b1 ready  | b0 freed       | refill in flight
BANK0_CHUNK        :  0            | (host -> 2)    | 2
host refill bank0  :  [.... writing chunk 2 ....]
                    ^
case A 及时:  chunk2 在游标到 4096 前写好 -> BANK0_CHUNK=2 ready -> 无缝继续
case B 晚到:  游标到 4096 但 bank0 还不是 chunk2
               -> 引擎 STALL (hold 当前点, STATUS_UNDERFLOW=1)
```

```
-> 主机写完 chunk2 + BANK0_CHUNK=2 + BANK_READY  
-> 引擎自动继续，不丢点/不串点
```

5.3 repeat_forever 流式重扫

`repeat_forever` 对一个有限（但很大）的流式扫描做反复扫掠：`fire` 时启动一个主机**后台回填线程**，循环把下一段填进空出的 bank。一次扫掠之内是**无缝**的；扫掠与扫掠之间的接缝是一个**短暂的安全 hold**（重新从 chunk 0 播种）。`host.engine_model.streaming_scan_play` 证明了播放序列、CURSOR 推进、以及晚到 STALL 行为。

6

N-slot 仿射扫描引擎

6.1 核心公式

每行边沿存一个 base tick 加 NUM_SLOTS 个定点系数；运行时 FPGA 对每个扫描点计算：

effective tick

```
effective_tick = base_tick + (sum_j coeff_j * slot_j) >>> COEFF_FRAC_BITS
```

其中 slot_j 是当前扫描点第 j 个 slot 的值（来自扫描点表那一行），COEFF_FRAC_BITS=8 是定点小数位数。**已经没有 x/y**——slot 是任意多个命名维度 s0, s1, ..., 每个绑定一个 duration 或 DAC 值字段 (SCAN_SLOT_KINDS=("duration", "dac")); channel 延时是固定值，不是扫描量)。这同一个 effective_tick 表达式被边沿 tick、loop 终点 tick、以及总线段起止 tick **复用**——这正是为什么 duration 与 DAC 值能任意组合地同时扫描，且只花一条 MAC 的 LUT。

6.2 为什么这是对的取舍

spec 最初设想的是逐通道游程编码（per-channel）+ 双 bank 全新存储。我们改成把仿射引擎**泛化**成 N 个 slot 的流式扫描点表，原因围绕 35T 的现实：

- 存储复杂度 $O(\text{edges}) + O(\text{points} \times \text{slots})$ 已达成 spec 的核心存储目标，但不需要每通道游程的状态机与地址逻辑。
- LUT 最省：一条比较器 + 一条仿射 MAC，而不是 62 个通道 player。
- 可验证：在无 Verilog 仿真器的前提下，仿射方案能被纯 Python 的逐周期行为模型忠实复刻。

7

模拟总线 DAC 引擎

7.1 段表编码

每条 10-bit DAC 总线有一张小的 LUTRAM 段表 (每 tick 组合读), 每段编码:

bus segment

```
start_tick / stop_tick : 段的起止 tick (仿射, 带 NUM_SLOTS 个系数, 同  
↔ effective_tick)  
start_value / stop_value: 段起止 DAC 码 (10 bit)  
mode                : edge/hold 或 ramp  
value_select (dual)  : start 与 stop 各一个选择子
```

总线码是**offset-binary**: 码 0 = 负满幅, 码 512 = 真零点 0 V, 码 1023 = 正满幅; 用户层(GUI/API/扫描表) 一律用带符号值 -512..+511 (0 = 0 V), 编译器在生成段/扫描点时自动 +512。引擎的空闲/复位/上电值是 **BUS_SAFE_VALUE** (= 中点码 512, 即 0 V), 所以未驱动的总线始终输出 0 V 而不是负满幅。**edge/hold** 段把输出保持在某个值; **ramp** 段在 start 到 stop 之间**线性插值**, 引擎本地每步走 1 个码 (不额外占边沿行)。**dual value_select** 让 start 与 stop 各自可以指向一个扫描 slot——于是一条 ramp 能**同时扫两个端点** (扫描-A → 扫描-B), 一条 edge/hold 段能跟随一个扫描的 DAC 码。

7.2 模拟 DAC ramp 与扫描端点: 前端脉冲实绘

每条模拟总线是一张小 LUTRAM 段表 (组合读), 段含 start/stop tick(仿射系数)+ start/stop 值 + mode(edge/ramp)+ **双 value_select**(start 和 stop 各一个)。ramp 段由引擎在本地按 tick 插值生成 10-bit 阶梯 (不占数字边沿行); 双 value_select 让一条 ramp 的**两个端点各跟一个 scan slot**(scanned-A → scanned-B), edge/hold 段则跟单个被扫 DAC 码。下图是**前端脉冲绘图器实绘**的 DAC 波形。

`host.engine_model.bus_play` 逐 tick 证明了总线/ramp 引擎, 包含被扫描的 ramp 端点。




Figure 7.1: 前端脉冲实绘：模拟总线 DAC 波形——保持 0、斜坡 0→1023、保持 1023。引擎在本地按 tick 插值生成 10-bit 阶梯; 双 value_select 允许斜坡两端各跟一个 scan slot。

8

三个子系统的深入讨论

本章把两个互相支撑的子系统讲透：**AXI4 突发上传**（怎么把程序映像快速写进 FPGA），以及**逐通道字面输出延时线**（一个 channel 被延时后到底输出什么）。延时线**独立于**仿射扫描引擎：边沿表始终按无延时的标称位置生成，延时只是一块加在引擎输出上的小型环形缓冲，把那条 channel 的输出整体往后推 d 个 tick。

8.1 AXI4 突发上传

主机到 FPGA 的传输是 JTAG-to-AXI: `jtag_axi_0`（一个由 Vivado Tcl 经 JTAG 线驱动的 AXI 主机）→ `axi_bram_ctrl_0` → 顶层后面区段译码的 BRAM 映像。架构上的关键事实是：这两个 IP 都配成**完整 AXI4**，而不是 **AXI4-Lite**。

为什么这很重要。在 JTAG-to-AXI 上，一次单拍写大约要 10 ms（开销在 JTAG 往返，不在数据量）。AXI4-Lite 没有突发，所以每个 32-bit 字都是一次事务；一张 4096 边沿的程序有几千个字，于是**每次 On Pulse 都是数秒级的上传**。完整 AXI4 允许主机每次事务发一个最多 256 拍（AWLEN 上限）的 INCR 突发，于是一段地址连续的字一个往返就写完，整张 4096 边沿映像因此降到约 **100 ms**。

配置的单一真相源在 `fpga/pulse_streamer/create_project.tcl`: `jtag_axi_0` 与 `axi_bram_ctrl_0` 都设 `CONFIG.PROTOCOL {AXI4}`，并把 `M_AXI_ID_WIDTH=1` / `ID_WIDTH=1` 对齐, 32-bit 数据/地址, `SUPPORTS_NARROW_BURST=0`。顶层 `zlc_pulse_streamer_top.v` 把主从 1:1 接线，**包含突发旁带**（`awlen/awsize/awburst/wlast` 等及读通道镜像）。

一个静默退化点

若漂回 **AXI4LITE**（或丢掉突发旁带），综合仍然成功，但 `-len N` 被忽略，上传又变回数秒级——**不会报错**。契约测试因此断言 `CONFIG.PROTOCOL {AXI4}` 存在、`{AXI4LITE}` 不存在，且主机侧 `m_axi_awlen/m_axi_awburst/m_axi_wlast` 与从机端口映射 `.s_axi_awlen(/.s_axi_awburst(/.s_axi_wlast(` 都已接线。

主机侧(`Zou_lab_control/neutral_atom/devices/axi_session.py`, `VivadoAxiStreamerSession`)。字写入先排成 (`byte_addr`, `value`) 队列，在 flush 时合并成突发：

- `_burst_runs` 按**插入顺序**（绝不全局排序）扫描待写队列，只合并严格地址连续（步长 4）的项，上限 `burst_max`（默认 256，夹到 `[1, 256]`）。**顺序是有载荷的**：COMMAND 上升沿是对**同一地址**的两次写（先 0 后 cmd），`BANK_READY` 的撤销/重置也是对同一地址的两次写；这些都必须保

持有序的单拍写，所以不会被合并或重排。

- `_write_burst_tcl` 发一条 `create_hw_axi_txn ... -len N -type write -burst INCR`。-burst INCR 是显式写的：Vivado 默认突发类型跨版本不保证是 INCR，而 FIXED 会把每拍都写到基地址（静默损坏）。对多字突发，-data 是一个拼接的十六进制大数，其最低位（最右）的字落在基地址——所以逐拍的字是高地址在前发出的，即连续值要逆序拼接。这个字节序是唯一一个容易静默出错的点。
- `_flush` 每个 Vivado 往返里发多个突发 (`write_batch` 限的是突发数，不是字数)，摊薄主机 $\leftrightarrow$ Tcl 的往返延迟。
- `axi_self_test` 是 warm-start 上电自检：突发写一段已知 ramp 进扫描 BRAM 区，再单拍读回比对，不一致就抛错。它正好抓住两类静默故障——突发 -data 字节序错、或仍是 Lite 的 bitstream 忽略了 -len——在任何真实脉冲上传之前。

上传不会随扫描点无界增长。点数超过 `2*bank_size` 的扫描，引擎播 2-bank ping-pong 窗口、主机流式回填（见前面“无限流式扫描”一章）：在游标 `CURSOR` 之后把空出的 bank 填上下一段并重置 `BANK_READY`。总扫描点数只受主机内存限制，晚到的回填只会 STALL (`STATUS_UNDERFLOW`)，绝不给出错误点。

8.2 逐通道字面输出延时线 (delay line)

channel 延时是一条加在引擎输出上的字面延时线，而不是烤进边沿表里的平移。定义极其简单：被延时 d 个 tick 的 channel，其延时后输出 `output_delayed[t] = output_undelayed[t-d]`， $t < d$ 之前恒为 0 (fire 之前为 0)。硬件就是一块普通的环形缓冲 (circular buffer)：它存下引擎那条 channel 的无延时输出，再在 d 个 tick 之后原样放出来。它只是把那条 channel 的输出整体延后，因此对任意信号都正确——周期的、非周期的、被 duration 扫描平移过的——都一样。这里没有任何周期性假设，不“跳整周期”，没有移位相位/成员关系，也没有逐扫描点的延时。一个 channel 的延时绝不改变另一个 channel 的时序（合并是不相交的直通 `out = (state_mask & ~delayed_mask) | delayed_out`）。延时均匀地与 duration 扫描、DAC 扫描、内层 repeat bracket 组合——“延时后的序列”恒等于“把那条 channel 延时 d 的无延时序列”。它不是扫描量：延时是每条 channel 的一个固定值，由主机作为常数携带 (`channel_delays`)。编译它的是 `compile_pulse_table_runtime_program` $\rightarrow$ `_pulse_table_edge_table` (`sequencer.py`)。

为什么是字面延时线，不是循环。循环视角 (GUI 预览显示的就是它) 会在 $t = 0$ 伪造一段“绕回来的尾巴”，于是 fire 之后的头几个脉冲变成序列尾部的幻影，破坏真实的实验起始。环形缓冲在 fire 时被清零，所以延时线让这头几个真实脉冲正确——第一帧是真实的 (在 $t = d$ 之前那条 channel 安静、保持 0，不是循环 $\%T$ 的预览样子)。延一个 channel 不会改变任何其它 channel 的周期，所以 T 保持不变。

literal delay line (延时 d)

```
cyclic (预览, 仅显示): [尾巴绕回][..... 原信号右移.....]    <- t=0 处有幻影
delay line (硬件, 真相): [.....0.....][原信号右移 d.....]    <- fire 前恒 0,
↪ 第一帧真实
```

机理要点 (一块普通环形缓冲，存输出、延后放出)：

- **TTL: 62 路全部可独立延时。** 引擎维护一条 `CHANNEL_COUNT` 位宽的环 (`tll_ring`，深度 `DELAY_DEPTH+1`)，每拍把当前的无延时 `state_mask` 写进环、写指针 `del_wptra` 前移一格。每条 channel 读它自己那一位在 `wptra - d_ch` 处的历史值 (`del_ch_ticks` 保存每条 channel 的 d)。 $d=0$ 就是逐位精确直通。合并出最终输出位掩码 `out = (state_mask & ~delayed_mask) | delayed_out`：被延时的位用环里取出的延时结果，其余位原样直通，于

是延时**绝不**打扰别的 channel。

- **DAC: 4 条总线各自可延时, 一条总线的 10 位共享一个延时。** 每条 10-bit 总线有一条**10 位宽的环** (`bus_ring`), 机制与 TTL 完全相同: 存下该总线的无延时输出值, d 个 tick 后放出。一条总线的 10 个 bit **共享同一个**逐总线延时 (`del_bus_ticks`), 所以整条总线 (固定值、被扫值、或 ramp) 都被整体延后, 而不是每 bit 单独延。
- **负延时 = 全局平移 G 。** 一条 channel 的 $-d$ 等价于其它**所有** channel 都 $+|d|$ 。主机把全局平移 $G = \max(0, -\min(\text{delays}))$ 折进每条 channel 的有效延时, 使最早的那条 channel 落在 0、缓冲只会看到 ≥ 0 的延时。零延时即直通。
- **有界 (这是字面延时线的根本性质)。** 延时范围是 $\pm 15 \mu\text{s}$; 缓冲深度 `DELAY_DEPTH = 2048` 个 tick (20 ns/tick 下约 $40 \mu\text{s}$) 足以覆盖它 (折进 G 后有效延时可达约 $30 \mu\text{s}$)。要把一个**非重复**信号延时 d , 你**必须**存下它 d 个 tick 的输出——这是字面延时线的本质; 但缓冲存的是**输出** (不是整张序列), 所以它很小。超过 `DELAY_DEPTH` 的延时会在 `validate` 与映像打包时**被清晰报错拒绝** (在上硬件之前, 绝不静默)。
- `repeat_forever` 把循环倒回稳态帧 (`loop_start_addr`), **而不是**倒回边沿 0; RTL (`zlc_edge_streamer.v` 与顶层) 里这是 `repeat_from_loop_start`。

无 Verilog 仿真下如何证明

预览保持循环 (只为显示) 。硬件/编译路径由一个字面延时真值预言 `delay_line_reference` (`output_delayed[t]=output_undelayed[t-d]`, fire 前为 0) 加上 `host/engine_model.py` 的 `rtl_mirror_play` 与环形缓冲镜像逐周期模型证明: 编译出的程序过这些周期模型后, 与延时线真值**逐 tick 相同** (覆盖 TTL 多 channel、DAC 逐总线、负延时折 G 、与 duration 扫描组合)。一个超过 `DELAY_DEPTH=2048` 的延时在 `validate_pulse_streamer_program` 与 `pack_program` 处都被清晰拒绝 (含 `DELAY_DEPTH=2048` 字样)。

8.3 DAC 总线延时与 TTL 完全同源

模拟总线 (DAC) 的延时机制和 TTL **完全相同**: 每条总线一条 10 位宽的环 (`bus_ring`), 存下该总线的无延时输出, d 个 tick 后放出。一条总线的**10 个 bit 共享一个**逐总线延时 (`del_bus_ticks`), 所以无论这个 DAC 值是**固定值**、**被扫值**, 还是**斜坡 (ramp)**, 整条总线都被同一个 d 整体延后; 在 $t < d$ 之前总线输出为 0。逐总线延时与 TTL 共享**同一个**全局平移 G , 并受**同一个**有界深度 `DELAY_DEPTH` 约束 (超过即清晰拒绝)。主机把每条总线的延时 tick 数作为常数携带 (`bus_delays`)。

成本小结。 TTL 用**一条** `CHANNEL_COUNT` 位宽的环、每条 DAC 总线用一条 10 位宽的环; 这些环都是**分布式 RAM (LUTRAM / distributed)**, **不占额外 BRAM** (`ram_style="distributed"`)。延时 tick 数走稠密的 CTRL 字 (`delay_ticks / bus_delay_ticks`) 下发, **没有**延时上传映像、**没有**迷你装载机。在 35T (`xc7a35t`) 上整套延时落地后仍有余量: LUT 约 59%、BRAM 39/50、DSP 约 58%。

8.4 逐通道 clk 输出 (把某通道直接接到时钟)

有时需要某个 TTL 引脚直接输出 FPGA 的 `clk` (例如给外部 DAC 喂时钟), 而引擎按 tick 寄存的输出本身**产生不出**一个时钟方波。为此顶层在引脚映射上加了一层**运行时可选的 clk 复用**: 一个 `CHANNEL_COUNT` 位的 `clk_enable` 掩码 (CTRL 字 `C_CLK_ENABLE`, 紧接 `BUS_DELAY_TICKS` 之后, 62 位占 2 个字) 随程序映像下发, 顶层据此把每个引脚选成

逐通道 clk 复用 (zlc_pulse_streamer_top.v)

```
assign out_final[n] = clk_en[n] ? clk : out[n];    // n: 0..CHANNEL_COUNT-1
// 引脚映射改为驱动 out_final (不是 out) : assign trig = out_final[6]; assign
↪ da_clk0 = out_final[28]; ...
```

所以被标记为 clk 的通道, 其引脚**恒等于 clk**, 与引擎完全无关。配套地, 主机编译时把该通道的 mask 位**强制清 0** (`masks[i] &= ~clk_enable`), 引擎**绝不驱动**它、也就**不会覆盖**clk 行为; `clk\_enable` 掩码由 `PulseTableState.clk\_channels` 经 `clk\_enable\_mask()` 算出, 随 `RuntimeSequenceProgram.clk\_enable` 打包进 CTRL 字(`host.image.CtrlWords.CLK_ENABLE`)。换哪条通道做 clk**只是改这份运行时掩码、不需要重新综合**; 但首次引入这套 mux 需要重新构建一次 bitstream。DAC 总线成员位不允许设成 clk (会破坏 DAC, GUI 已禁用)。这套 mux 是纯组合逻辑、几乎不占资源。

8.5 两件没有下放进 sequencer 的事

两条边界澄清, 免得把架构搞混:

- **解耦**。sequencer / 边沿流送器**不含**任何相机/触发判断。引擎只播放数字边沿、模拟总线段、和逐通道输出延时线; 引擎 HDL (`zlc_edge_streamer.v`) 里**没有**相机/采集/读出/判定逻辑。触发通道只是引擎驱动的又一路数字输出——**何时**计数或阈值判定的决定, 住在采集/反馈子系统 (`subsystems / readout`), 不在 timing 里。
- **对齐到 tick (单一来源)**。时钟只能落在整 tick ($\geq 20\text{ ns}$), 所以字面时间值会被对齐到网格, 且只有一个对齐来源 `PulseTableState.snapped()` (`timing/pulse_table.py`): period 持续时间**向下取整到 ≥ 1 tick** (绝不塌到 0, 例如 $5\text{ ns} \rightarrow 20\text{ ns}$); channel 延时与扫描点值**四舍五入到最近 tick** (半值远离零、保号); DAC 扫描点取最近整数码; 而 slot **表达式** (`s0`、`20+s0` 等非数字) **原样保留**——编译器改为对它的仿射 base 取整, 所以绑定永不被破坏。它**永不报错** (自动对齐), 对应共聚焦的 `align_to_resolution`。脉冲传输 API 在 `sequencer.timing_payload_to_dict` 里用 `snapped()` 一次性对齐整个状态, GUI 则通过 `align_to_resolution` 背书的分辨率控件逐字段套同一规则——两端共享 `timing/pulse_table.py` 的同一套取整逻辑, 所以**所见即所跑**。

9

容量与资源预算

9.1 35T 上解出的容量

容量由 `host.image.solve_capacity(part, channel_count)` 求解（单一真相源），目标 $\leq 90\%$ RAMB36。35T 上解出：

```
solve_capacity('xc7a35tfgg484-2')
```

```
4096 edges + bank_size 2048 (4096 resident) + UNBOUNDED streaming  
RAMB36: 39/50 = 78%      LUT: 26%   FF: 12%   DSP: 9%
```

三块并行边沿 BRAM (tick/coeff/mask) + 扫描窗口 BRAM 占了 RAMB36 预算的大头；**总线段表是 LUTRAM (distributed)，不占 RAMB36**——因为总线/ramp 引擎每 tick 组合读它们，搬进 BRAM 会破坏组合读。**字面延时线**（TTL 的 `CHANNEL_COUNT` 位宽环 + 每条 DAC 总线的 10 位宽环，深度 `DELAY_DEPTH=2048`）同样是分布式 RAM，**不占额外 BRAM**——这正是字面延时线能放进 35T 的原因：它存的是**输出**（而非整张序列），所以缓冲很小。把延时线一并算进去后，35T 的整体落地约为 LUT 59%、BRAM 39/50、DSP 58%。Vivado `report_utilization` / `report_timing_summary` 是最终权威，Python 估算只是预算指引。

10

编译与上传流程

10.1 build / program / run

FPGA 侧只有一个入口 `fpga\textbackslash build\_and\_program.bat` (内部跑 `create_project.tcl` → `program_fpga.tcl`), server 入口是 `fpga\textbackslash run\_server.bat` (jtag-axi 后端):

PowerShell

```
.\fpga\build_and_program.bat --check      # 不连板的 HDL 综合 + 容量自查
.\fpga\build_and_program.bat              # build + program
.\fpga\run_server.bat --check-config      # 打印
↪ project/bit/ltx/xdc/channels/clock/capacity
.\fpga\run_server.bat                    # 启动常驻 hw_axi server (host
↪ 0.0.0.0, port 18861)
```

`create_project.tcl` 生成 `jtag_axi` + `axi_bram_ctrl` + 5 块 BRAM (三块并行边沿 tick/coeff/mask + 扫描窗口 + 总线映像), 并用 `zlc_force_latency2` 把边沿 BRAM 强制成 `READ_LATENCY_B=2`。逐通道/逐总线的字面延时线是**分布式 RAM (LUTRAM)** 环形缓冲, **不占额外 BRAM**、也没有延时上传映像。产物 `zlc_pulse_streamer_top.\{bit,ltx\}` 落在 `fpga\textbackslash build\textbackslash ps\textbackslash ps.runs\textbackslash impl_1` (工程用短名 `ps` 是为了让 Vivado 深层的 `run / .Xil` 临时路径不超过 Windows MAX_PATH 限制, 同时构建仍然留在仓库内的 `fpga\textbackslash build`, 不挪到别处)。server 加载 `.ltx` 是为了在比特流里定位 `jtag_axi` 核 (即 `hw_axi`), 所以 bit 与 ltx 必须来自**同一次编译**。

10.2 一次上传里发生了什么

1. 主机校验程序: `validate_pulse_streamer_program` 检查边沿/扫描点/位宽/通道不越界, 并校验**全局有效 tick 单调** (扫描不会把合并后的边沿顺序打乱; 会打乱顺序的扫描被拒绝, 而不是悄悄丢点)。
2. `host.image.pack_program` 把整张程序打包成 32-bit BRAM 映像: CTRL 标量 + 三块并行边沿表 + 2-bank 扫描窗口 + 总线段映像。

3. `prepare`: 发 SAFE → AXI 写映像 → arm 两个扫描 bank (写 `BANK_READY/BANK*_CHUNK`) → 发 LOAD (等 `STATUS_LOADED`)。
4. `fire`: 发 FIRE; 对流式/重复扫描, 启动后台回填线程。
5. `wait_done`: 轮询 STATUS (DONE 位) , 并跟随 CURSOR 回填空出来的 bank。
`repeat_forever` 永不置 DONE, 所以必须给 timeout 或主动 stop。

全部在硬件前被 Python 验证

`pack_program`↔`unpack_program` 往返、`engine_model` 的逐周期等价 (1-tick 预取 / 边界无缝 / 流式 ping-pong / 总线 ramp) 、以及 `VivadoAxiStreamerSession` 的 `pack`→`upload`→`LOAD`→`fire` 流程 (Tcl 执行器可注入, 无需 Vivado) 都有契约测试覆盖。仓库没有 Verilog 仿真器, 这套 Python 证据是硬件 bring-up 前的正确性保证。